

Relatório do Laboratório 5 - Estratégias Evolutivas

1 Breve Explicação em Alto Nível da Implementação

O objetivo deste laboratório é realizar uma comparação de desempenho entre dois métodos de Estratégias Evolutivas (Evolution Strategies - ES): a Estratégia Evolutiva Simples (SES) e o algoritmo CMA-ES (Covariance Matrix Adaptation Evolution Strategy), aplicando-os a funções de benchmark amplamente utilizadas na literatura de otimização: *Translated Sphere*, Ackley, Rastrigin e Schaffer.

1.1 Estratégia Evolutiva Simples

A Estratégia Evolutiva Simples (SES) é um algoritmo estocástico de otimização baseado nos princípios da evolução biológica. O método consiste em gerar, a cada iteração, uma população de λ candidatos (samples) amostrados a partir de uma distribuição multivariada normal com média \mathbf{m} e matriz de covariância \mathbf{C} . Em seguida, selecionam-se as μ melhores soluções com base em sua aptidão (função *fitness*), as quais são utilizadas para atualizar os parâmetros da distribuição — ou seja, a nova média \mathbf{m} e a matriz de covariância \mathbf{C} . Este processo iterativo continua até que se atinja um critério de parada, como a convergência para um ótimo global ou o número máximo de iterações.

Para a implementação da SES, utilizaremos estratégias específicas de atualização para a média e a matriz de covariância, que serão detalhadas a seguir.

$$\mathbf{m}^{(g+1)} = \frac{1}{\mu} \sum_{i=1}^{\mu} \mathbf{s}_{i:\lambda}^{(g+1)} \quad (1)$$

$$\mathbf{C}^{(g+1)} = \frac{1}{\mu} \sum_{i=1}^{\mu} \left(\mathbf{s}_{i:\lambda}^{(g+1)} - \mathbf{m}^{(g)} \right) \left(\mathbf{s}_{i:\lambda}^{(g+1)} - \mathbf{m}^{(g)} \right)^T \quad (2)$$

2 Figuras Comprovando Funcionamento do Código

2.1 Função *Translated Sphere*

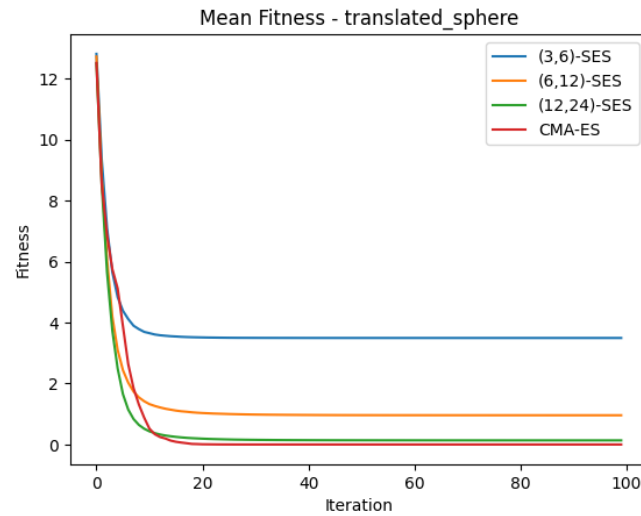


Figura 1: gráfico de *fitness* médio para a função *translated sphere*.




Figura 2: gráfico de melhor *fitness* para a função *translated sphere*.

2.2 Função Ackley




Figura 3: gráfico de *fitness* médio para a função Ackley.

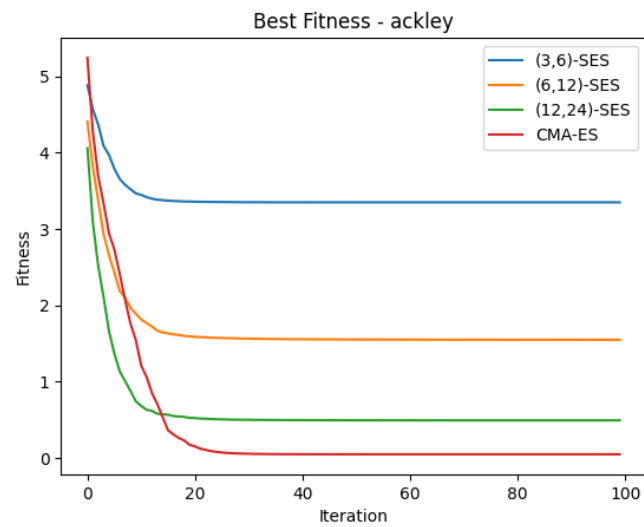


Figura 4: gráfico de melhor *fitness* para a função Ackley.

2.3 Função Rastrigin




Figura 5: gráfico de *fitness* médio para a função Rastrigin.




Figura 6: gráfico de melhor *fitness* para a função Rastrigin.

2.4 Função Schaffer




Figura 7: gráfico de *fitness* médio para a função Schaffer.




Figura 8: gráfico de melhor *fitness* para a função Schaffer.

3 Discussões e Conclusões

- Por que você acha que os resultados são diferentes para cada função?

As variações de desempenho entre os algoritmos estão ligadas às propriedades topológicas das funções. A *Translated Sphere*, suave e unimodal, favorece o CMA-ES, que explora o espaço de forma eficiente. Já a Schaffer, ruidosa e multimodal, beneficia o SES com maior população, devido à maior diversidade amostral. Funções intermediárias como Ackley e Rastrigin evidenciam essas diferenças: a Ackley se adapta bem ao CMA-ES, enquanto a Rastrigin favorece SES com mais amostras por sua alta multimodalidade. A escolha do algoritmo ideal depende, portanto, da suavidade, ruído e complexidade da função.

- Comente de forma sucinta sobre os resultados para cada um dos algoritmos e das funções, principalmente sobre questões como convergência, incluindo sobre convergência para mínimo local.

De modo geral, variantes do SES com maior número de amostras por geração, como o (12,24)-SES, apresentaram melhor convergência, graças à maior capacidade de exploração do espaço de busca e escape de mínimos locais.

Na comparação com o CMA-ES, este mostrou desempenho superior nas funções *Translated Sphere* e Ackley, beneficiado pela adaptação dinâmica da matriz de covariância, que melhora a direcionalidade da busca.

Na função Rastrigin, altamente multimodal, o CMA-ES foi superado apenas pelo (12,24)-SES, cuja exploração mais ampla favoreceu a fuga de mínimos locais.

Já função Schaffer, caracterizada por forte ruído e alta oscilação, o CMA-ES teve dificuldade de convergência e desempenho inferior aos SES com maior população, como o (6,12)-SES e o (12,24)-SES. Nesses casos, a diversidade amostral e a maior capacidade de mutação dos SES contribuíram para uma exploração mais robusta, evitando que o algoritmo se fixasse melhores mínimos locais.

Em resumo, o CMA-ES é mais eficiente em funções suaves, enquanto SES com maior população se destacam em funções complexas e ruidosas.